

Facultad de Ingeniería

Carrera de Ciencia de Datos e IA

Informe de Actividad de Investigación Formativa

Tema

**Desarrollo de un Sistema Predictivo para Evaluar la Probabilidad
de Impago en Clientes Financieros**

Periodo Académico

Abril 2026 – Agosto 2026

Índice

1. Autores	2
2. Personal Académico	2
3. Resultados de Aprendizaje de la Asignatura	2
4. Tema de la Actividad de la Investigación Formativa	2
5. Objetivos de la(s) Actividad(es)	2
6. Fecha de la Ejecución	3
7. Desarrollo del Informe	3
7.1. Introducción	3
7.2. Descripción de la Metodología	4
7.3. Descripción de la(s) Acción(es) Realizadas	4
7.4. Resultados	5
7.5. Bibliografía	5
8. Anexos (Evidencias)	5

1. Autores

- López Cabrera Lenin Francisco
- Jose Mario Camacho Monar

2. Personal Académico

- Director de Carrera: Milton Paúl López Ramos
- Profesor de Asignatura: Estalin Fabian Mejía Hidalgo

3. Resultados de Aprendizaje de la Asignatura

El desarrollo de esta actividad de investigación formativa permite aplicar conocimientos relacionados con la gestión de datos, el diseño de arquitecturas de persistencia híbrida, la preparación de información para analítica predictiva, la construcción de modelos de Machine Learning y el despliegue de soluciones interactivas orientadas a la toma de decisiones. Además, fortalece competencias de análisis, interpretación de resultados, comunicación técnica y resolución de problemas reales mediante herramientas tecnológicas actuales.

4. Tema de la Actividad de la Investigación Formativa

Desarrollo de un Sistema Predictivo para Evaluar la Probabilidad de Impago en Clientes Financieros.

5. Objetivos de la(s) Actividad(es)

Objetivo general: Diseñar e implementar una solución analítica e infraestructural integral que combine una arquitectura de persistencia híbrida, basada en SQL Server y MongoDB, con el entrenamiento, evaluación y despliegue de modelos de Machine Learning supervisados y no supervisados para evaluar la probabilidad de impago en clientes financieros.

Objetivos específicos:

- Desarrollar un pipeline reproducible de preparación, limpieza y transformación de datos utilizando Python en entornos Jupyter Notebook.
- Implementar una infraestructura de persistencia híbrida que permita almacenar, consultar y gestionar datos estructurados y semiestructurados.

- Construir, optimizar y comparar modelos de aprendizaje supervisado y no supervisado aplicados al análisis del riesgo de impago.
- Evaluar el desempeño de los modelos mediante métricas estadísticas avanzadas que permitan seleccionar la solución más adecuada.
- Desplegar una aplicación interactiva o tablero de control en Streamlit que facilite la visualización de datos, resultados y predicciones en tiempo real.

6. Fecha de la Ejecución

Periodo académico Abril 2026 – Agosto 2026.

7. Desarrollo del Informe

7.1. Introducción

En el sector financiero actual, la capacidad de anticipar el riesgo de impago se ha convertido en un factor estratégico para la toma de decisiones, la sostenibilidad operativa y la reducción de pérdidas asociadas al crédito. Las instituciones financieras gestionan grandes volúmenes de información provenientes de múltiples fuentes, tales como historiales de pago, características sociodemográficas, comportamiento transaccional, niveles de endeudamiento y registros internos de clientes. Sin embargo, el valor de estos datos depende no solo de su almacenamiento, sino también de la calidad de su gestión, procesamiento, análisis y aprovechamiento mediante soluciones tecnológicas capaces de transformar la información en conocimiento accionable.

En este contexto, el presente proyecto propone el desarrollo de un sistema predictivo orientado a evaluar la probabilidad de impago en clientes financieros, integrando una infraestructura de persistencia híbrida con técnicas de analítica predictiva y modelos de Machine Learning. La solución contempla el uso combinado de SQL Server y MongoDB, con el propósito de aprovechar las fortalezas de las bases de datos relacionales para garantizar integridad, consistencia y gobernanza de la información estructurada, así como la flexibilidad de las bases de datos NoSQL para almacenar y consultar datos semiestructurados o de alta variabilidad. Esta arquitectura busca responder a las necesidades actuales de escalabilidad, trazabilidad y disponibilidad de datos en entornos financieros modernos.

El proyecto incluye el diseño e implementación de un pipeline reproducible de preparación y transformación de datos utilizando Python en entornos Jupyter Notebook. Dicho proceso comprende actividades esenciales como la limpieza de datos, el tratamiento de valores faltantes, la detección de inconsistencias, la codificación de variables, la normalización o estandarización de atributos y la generación de características relevantes para el análisis. Cada decisión de preprocesamiento será justificada técnicamente, considerando su impacto en la calidad del conjunto de datos y en el desempeño de los modelos predictivos.

Asimismo, se construirán, optimizarán y compararán algoritmos de aprendizaje supervisado y no supervisado. Los modelos supervisados permitirán estimar la probabilidad de impago a partir de datos históricos etiquetados, mientras que las técnicas no supervisadas facilitarán la identificación de patrones, segmentos de clientes o comportamientos atípicos que puedan aportar valor al análisis del riesgo financiero. La selección del modelo óptimo se sustentará en métricas estadísticas avanzadas, tales como precisión, sensibilidad, especificidad, F1-score, matriz de confusión, curva ROC y AUC, además de otros indicadores pertinentes según la naturaleza del problema y el balance de clases presente en los datos.

Finalmente, la solución será complementada con el despliegue de una aplicación interactiva o tablero de control desarrollado en Streamlit, mediante el cual los usuarios podrán explorar los datos, visualizar resultados, consultar métricas de desempeño e interactuar en tiempo real con los modelos generados. De esta manera, el sistema no solo busca ofrecer una predicción técnica sobre el riesgo de impago, sino también proporcionar una herramienta práctica de apoyo a la toma de decisiones, fortaleciendo la gestión del riesgo crediticio y demostrando la integración efectiva entre infraestructura de datos, analítica avanzada y despliegue de modelos de Machine Learning.

7.2. Descripción de la Metodología

La metodología del proyecto se desarrollará bajo un enfoque aplicado, experimental y tecnológico. En primer lugar, se realizará la recopilación y análisis de los datos financieros disponibles, identificando las variables relevantes para la evaluación del riesgo de impago. Posteriormente, se diseñará una arquitectura de persistencia híbrida que integre SQL Server para la gestión de datos estructurados y MongoDB para el manejo de información semiestructurada o flexible.

El procesamiento de datos se efectuará mediante Python en Jupyter Notebook, utilizando un pipeline reproducible que incluya limpieza, transformación, análisis exploratorio, selección de variables y preparación del conjunto de entrenamiento. Luego, se entrenarán modelos de Machine Learning supervisados para la predicción del impago y modelos no supervisados para segmentación o detección de patrones. Finalmente, los resultados serán integrados en una aplicación desarrollada con Streamlit, permitiendo la interacción con los datos y los modelos generados.

7.3. Descripción de la(s) Acción(es) Realizadas

Durante la fase de ejecución y seguimiento se plantean acciones como el levantamiento de requerimientos, la organización de las fuentes de datos, la construcción de la base relacional en SQL Server, la configuración de colecciones en MongoDB, la creación del pipeline de preprocesamiento y el entrenamiento de modelos predictivos. También se realizará el seguimiento del desempeño de cada modelo mediante métricas estadísticas y validación de resultados.

En la fase de socialización y reflexión se presentarán los resultados obtenidos mediante visualizaciones, reportes y un tablero interactivo. Esta etapa permitirá analizar el alcance de la solución, interpretar los hallazgos más relevantes, reconocer limitaciones del modelo y proponer mejoras futuras relacionadas con la calidad de los datos, la optimización de algoritmos y el despliegue en

entornos productivos.

7.4. Resultados

Como resultado esperado, se obtendrá un sistema predictivo capaz de estimar la probabilidad de impago en clientes financieros a partir de datos previamente procesados y almacenados en una infraestructura híbrida. El proyecto permitirá comparar distintos algoritmos, seleccionar el modelo con mejor desempeño y presentar los resultados mediante una interfaz interactiva que apoye el análisis del riesgo crediticio.

Además, se espera evidenciar la utilidad de combinar bases de datos relacionales y NoSQL en proyectos de analítica predictiva, así como demostrar la importancia de un pipeline reproducible para garantizar transparencia, trazabilidad y consistencia en el tratamiento de datos. El producto final integrará almacenamiento, procesamiento, modelado y visualización en una solución coherente orientada a resolver una problemática real del entorno financiero.

7.5. Bibliografía

- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media.
- Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.
- Microsoft. (2024). *SQL Server Documentation*. Microsoft Learn.
- MongoDB. (2024). *MongoDB Manual*. MongoDB Documentation.
- Streamlit. (2024). *Streamlit Documentation*. Streamlit Docs.

8. Anexos (Evidencias)

En esta sección se incluirán las evidencias correspondientes al desarrollo del proyecto, tales como capturas de pantalla de la arquitectura de bases de datos, notebooks de procesamiento, resultados de entrenamiento, métricas de evaluación, visualizaciones del tablero en Streamlit y demás recursos que respalden la ejecución de la actividad de investigación formativa.