

Facultad de Ingeniería

Carrera de Ciencia de Datos e IA

Informe de Actividad de Investigación Formativa

Tema

**Desarrollo de un Sistema Predictivo para Evaluar la Probabilidad
de Impago en Clientes Financieros**

Periodo Académico

Abril 2026 – Agosto 2026

Índice

1. Autores	2
2. Personal Académico	2
3. Resultados de Aprendizaje de la Asignatura	2
4. Tema de la Actividad de la Investigación Formativa	2
5. Objetivos de la(s) Actividad(es)	2
6. Fecha de la Ejecución	3
7. Desarrollo del Informe	3
7.1. Introducción	3
7.2. Descripción de la Metodología	4
7.3. Descripción de la(s) Acción(es) Realizadas	5
7.4. Resultados	7
7.5. Bibliografía	8
8. Anexos (Evidencias)	8

1. Autores

- López Cabrera Lenin Francisco
- Jose Mario Camacho Monar
- Brayan Gualberto Cárdenas Medina
- Dennys Alexander Becerra Gavidia
- Dennis Iván Sánchez Palomo

2. Personal Académico

- Director de Carrera: Milton Paúl López Ramos
- Profesor de Asignatura: Estalin Fabian Mejía Hidalgo

3. Resultados de Aprendizaje de la Asignatura

El desarrollo de esta actividad de investigación formativa permite aplicar conocimientos relacionados con la gestión de datos, el diseño de arquitecturas de persistencia híbrida, la preparación de información para analítica predictiva, la construcción de modelos de Machine Learning y el despliegue de soluciones interactivas orientadas a la toma de decisiones. Además, fortalece competencias de análisis, interpretación de resultados, comunicación técnica y resolución de problemas reales mediante herramientas tecnológicas actuales.

4. Tema de la Actividad de la Investigación Formativa

Desarrollo de un Sistema Predictivo para Evaluar la Probabilidad de Impago en Clientes Financieros.

5. Objetivos de la(s) Actividad(es)

Objetivo general: Diseñar e implementar una solución analítica e infraestructural integral que combine una arquitectura de persistencia híbrida, basada en SQL Server y MongoDB, con el entrenamiento, evaluación y despliegue de modelos de Machine Learning supervisados y no supervisados para evaluar la probabilidad de impago en clientes financieros.

Objetivos específicos:

- Desarrollar un pipeline reproducible de preparación, limpieza y transformación de datos utilizando Python en entornos Jupyter Notebook.
- Implementar una infraestructura de persistencia híbrida que permita almacenar, consultar y gestionar datos estructurados y semiestructurados.
- Construir, optimizar y comparar modelos de aprendizaje supervisado y no supervisado aplicados al análisis del riesgo de impago.
- Evaluar el desempeño de los modelos mediante métricas estadísticas avanzadas que permitan seleccionar la solución más adecuada.
- Desplegar una aplicación interactiva o tablero de control en Streamlit que facilite la visualización de datos, resultados y predicciones en tiempo real.

6. Fecha de la Ejecución

Periodo académico Abril 2026 – Agosto 2026.

7. Desarrollo del Informe

7.1. Introducción

En el sector financiero actual, la capacidad de anticipar el riesgo de impago se ha convertido en un factor estratégico para la toma de decisiones, la sostenibilidad operativa y la reducción de pérdidas asociadas al crédito. Las instituciones financieras gestionan grandes volúmenes de información provenientes de múltiples fuentes, tales como historiales de pago, características sociodemográficas, comportamiento transaccional, niveles de endeudamiento y registros internos de clientes. Sin embargo, el valor de estos datos depende no solo de su almacenamiento, sino también de la calidad de su gestión, procesamiento, análisis y aprovechamiento mediante soluciones tecnológicas capaces de transformar la información en conocimiento accionable.

En este contexto, el presente proyecto propone el desarrollo de un sistema predictivo orientado a evaluar la probabilidad de impago en clientes financieros, integrando una infraestructura de persistencia híbrida con técnicas de analítica predictiva y modelos de Machine Learning. La solución contempla el uso combinado de SQL Server y MongoDB, con el propósito de aprovechar las fortalezas de las bases de datos relacionales para garantizar integridad, consistencia y gobernanza de la información estructurada, así como la flexibilidad de las bases de datos NoSQL para almacenar y consultar datos semiestructurados o de alta variabilidad. Esta arquitectura busca responder a las necesidades actuales de escalabilidad, trazabilidad y disponibilidad de datos en entornos financieros modernos.

El proyecto incluye el diseño e implementación de un pipeline reproducible de preparación y transformación de datos utilizando Python en entornos Jupyter Notebook. Dicho proceso comprende

actividades esenciales como la limpieza de datos, el tratamiento de valores faltantes, la detección de inconsistencias, la codificación de variables, la normalización o estandarización de atributos y la generación de características relevantes para el análisis. Cada decisión de preprocesamiento será justificada técnicamente, considerando su impacto en la calidad del conjunto de datos y en el desempeño de los modelos predictivos.

Asimismo, se construirán, optimizarán y compararán algoritmos de aprendizaje supervisado y no supervisado. Los modelos supervisados permitirán estimar la probabilidad de impago a partir de datos históricos etiquetados, mientras que las técnicas no supervisadas facilitarán la identificación de patrones, segmentos de clientes o comportamientos atípicos que puedan aportar valor al análisis del riesgo financiero. La selección del modelo óptimo se sustentará en métricas estadísticas avanzadas, tales como precisión, sensibilidad, especificidad, F1-score, matriz de confusión, curva ROC y AUC, además de otros indicadores pertinentes según la naturaleza del problema y el balance de clases presente en los datos.

Finalmente, la solución será complementada con el despliegue de una aplicación interactiva o tablero de control desarrollado en Streamlit, mediante el cual los usuarios podrán explorar los datos, visualizar resultados, consultar métricas de desempeño e interactuar en tiempo real con los modelos generados. De esta manera, el sistema no solo busca ofrecer una predicción técnica sobre el riesgo de impago, sino también proporcionar una herramienta práctica de apoyo a la toma de decisiones, fortaleciendo la gestión del riesgo crediticio y demostrando la integración efectiva entre infraestructura de datos, analítica avanzada y despliegue de modelos de Machine Learning.

7.2. Descripción de la Metodología

La metodología del proyecto se desarrollará bajo un enfoque aplicado, experimental y tecnológico. En primer lugar, se realizará la recopilación y análisis de los datos financieros disponibles, identificando las variables relevantes para la evaluación del riesgo de impago. Posteriormente, se diseñará una arquitectura de persistencia híbrida que integre SQL Server para la gestión de datos estructurados y MongoDB para el manejo de información semiestructurada o flexible.

Para la ejecución del proyecto se utilizarán herramientas orientadas a cubrir las fases de almacenamiento, procesamiento, modelado, visualización y control del desarrollo. La base de datos relacional será implementada en SQL Server 2022, mientras que MongoDB será empleado como base de datos NoSQL para complementar la persistencia de información flexible. El procesamiento de datos y la construcción de modelos de Machine Learning se realizarán con Python 3.12 en entornos Jupyter Notebook, utilizando principalmente las librerías pandas y scikit-learn. Para la visualización y socialización de resultados se emplearán Streamlit y matplotlib, y para el control de versiones se trabajará con Git y GitHub.

- **Base de datos relacional:** SQL Server 2022.
- **Base de datos NoSQL:** MongoDB.
- **Procesamiento y Machine Learning:** Python 3.12, Jupyter Notebook, pandas y scikit-learn.
- **Visualización:** Streamlit y matplotlib.

- **Control de versiones:** Git y GitHub.

El procesamiento de datos se efectuará mediante un pipeline reproducible que incluya limpieza, transformación, análisis exploratorio, selección de variables y preparación del conjunto de entrenamiento. Luego, se entrenarán modelos de Machine Learning supervisados para la predicción del impago y modelos no supervisados para segmentación o detección de patrones. Finalmente, los resultados serán integrados en una aplicación desarrollada con Streamlit, permitiendo la interacción con los datos y los modelos generados.

7.3. Descripción de la(s) Acción(es) Realizadas

Durante la fase de ejecución y seguimiento se seleccionó como fuente principal el conjunto de datos *Default of Credit Card Clients*, obtenido del repositorio UCI Machine Learning Repository. Este dataset corresponde a un problema de clasificación asociado al incumplimiento de pagos de clientes de tarjetas de crédito en Taiwán, y contiene 30.000 registros con información demográfica, crediticia, historial de pagos, montos facturados, pagos realizados y una variable objetivo que indica si el cliente incumplió el pago del mes siguiente. De acuerdo con la documentación del repositorio, el conjunto contiene 23 características predictoras y está orientado a evaluar la probabilidad de incumplimiento crediticio.

A partir del diccionario de variables revisado en la documentación del proyecto, se organizó la información del dataset en grupos funcionales para facilitar su interpretación y posterior uso en el proceso predictivo.

Para la predicción se trabajará con variables que combinan información demográfica, capacidad crediticia, historial de pagos y comportamiento financiero reciente. Estas variables permiten representar tanto el perfil del cliente como su conducta de pago antes de estimar la probabilidad de impago.

Para migrar la información hacia SQL Server se utilizó el script `ScriptsSQL/SQLQuery1.sql`. En primer lugar, el script crea la base de datos `CC_Client` y define tablas de dimensión para normalizar los catálogos de sexo, educación, estado civil, meses de referencia y estatus de pago. Posteriormente, crea la tabla central `dim_cliente`, donde se almacena el perfil del cliente, y las tablas de hechos `historial_pagos` y `riesgo_crediticio`, utilizadas para registrar el comportamiento mensual y la variable objetivo del modelo.

Luego, el proceso de migración carga el archivo del dataset en una tabla temporal o de paso denominada `staging_credit_cards`. Esta tabla conserva la estructura original del archivo, incluyendo variables demográficas, límite de crédito, historial de pago, montos facturados, pagos realizados y el indicador de incumplimiento. A partir de esta tabla, el script inserta los datos normalizados en `dim_cliente` y `riesgo_crediticio`. Finalmente, mediante una operación `CROSS APPLY`, transforma las columnas mensuales del historial financiero en registros por cliente y mes dentro de `historial_pagos`, lo que facilita consultas analíticas, auditoría del comportamiento crediticio y posterior preparación de datos para modelos predictivos.

Cuadro 1: Diccionario general de variables del dataset.

Variable o grupo		Descripción
<i>ID</i>		Identificador único de cada cliente dentro del conjunto de datos.
<i>LIMIT_BAL</i>		Monto de crédito otorgado al cliente, incluyendo crédito individual y familiar.
<i>SEX</i>		Género del cliente: 1 representa masculino y 2 representa femenino.
<i>EDUCATION</i>		Nivel educativo: 1 posgrado, 2 universidad, 3 bachillerato y 4 otros.
<i>MARRIAGE</i>		Estado civil: 1 casado, 2 soltero y 3 otros.
<i>AGE</i>		Edad del cliente expresada en años.
<i>PAY_0</i> a <i>PAY_6</i>		Historial de estado de pago mensual entre septiembre y abril de 2005. La escala representa pago puntual, crédito revolvente o retrasos de uno a nueve meses.
<i>BILL_AMT1</i> <i>BILL_AMT6</i>	a	Montos de los estados de cuenta mensuales entre septiembre y abril de 2005.
<i>PAY_AMT1</i> <i>PAY_AMT6</i>	a	Montos pagados por el cliente en los meses correspondientes al historial financiero.
<i>default payment next month</i>		Variable objetivo del modelo: 1 indica incumplimiento de pago y 0 indica no incumplimiento.

Cuadro 2: Variables consideradas para el modelo predictivo.

Grupo	Variables	Uso en la predicción
Perfil del cliente	<i>SEX</i> , <i>EDUCATION</i> , <i>MARRIAGE</i> , <i>AGE</i>	Caracterizan al cliente mediante género, nivel educativo, estado civil y edad. Ayudan a identificar patrones demográficos relacionados con el riesgo crediticio.
Capacidad crediticia	<i>LIMIT_BAL</i>	Representa el límite de crédito otorgado y permite aproximar el nivel de exposición financiera del cliente.
Historial de pago	<i>PAY_0</i> , <i>PAY_2</i> , <i>PAY_3</i> , <i>PAY_4</i> , <i>PAY_5</i> , <i>PAY_6</i>	Refleja retrasos o cumplimiento mensual, siendo uno de los grupos más relevantes para detectar riesgo de impago.
Montos facturados	<i>BILL_AMT1</i> <i>BILL_AMT6</i> a	Permiten analizar el nivel de deuda mensual acumulada por el cliente.
Pagos realizados	<i>PAY_AMT1</i> <i>PAY_AMT6</i> a	Indican los pagos efectuados previamente y ayudan a comparar deuda facturada frente a capacidad o voluntad de pago.
Variable objetivo	<i>default payment next month</i>	Clase a predecir: incumplimiento o no incumplimiento del pago del mes siguiente.

Adicionalmente, se utilizó el script `ScriptsSQL/SQLQuery2.sql` para complementar la infraestructura de consulta, gobierno y seguridad de la base de datos. Este script crea vistas estructuradas, como `vw_ml_dataset`, que reconstruye un dataset plano listo para procesos de Machine Learning a partir de las tablas normalizadas, y `vw_cliente_detallado`, que integra la información del cliente con descripciones legibles de sexo, educación y estado civil para facilitar el análisis exploratorio. También incorpora índices no agrupados sobre `historial_pagos` y `riesgo_crediticio`, con el objetivo de mejorar el rendimiento de consultas analíticas y filtrados por la variable objetivo.

De forma general, `SQLQuery2.sql` fortalece la administración de la base de datos mediante una tabla de auditoría y un disparador sobre `riesgo_crediticio`, capaz de registrar operaciones de inserción, actualización y eliminación. Además, define roles y usuarios para separar permisos de lectura y administración, estableciendo un rol de analista con acceso de consulta y un rol administrador con control sobre la base de datos. Finalmente, incluye una estrategia de respaldo y restauración mediante backups completos, diferenciales y de log transaccional, lo que contribuye a la disponibilidad, recuperación y gobernanza de la información del proyecto.

La conexión entre la aplicación, las bases de datos y el proceso analítico se implementó desde el archivo `Scrip_pynb/db_connections.py`. Este módulo centraliza las funciones de conexión a SQL Server y MongoDB: en SQL Server se conecta a la base `CC_Client` mediante `pyodbc`, mientras que en MongoDB establece comunicación con el servidor local y retorna la base `ML_Experiments`. Además, incluye funciones para cargar el dataset plano desde la vista `vw_ml_dataset` y el dataset detallado desde `vw_cliente_detallado`, utilizando `pandas` para transformar las consultas SQL en estructuras de datos listas para análisis, visualización y modelado.

Para la etapa de modelado predictivo se trabajó con el notebook `Scrip_pynb/gradient_boosting.ipynb`. En este archivo se desarrolla el flujo de Machine Learning orientado a la predicción de impago mediante modelos de Gradient Boosting, incluyendo técnicas como XGBoost y LightGBM. El notebook contempla la carga de datos, identificación de la variable objetivo, análisis exploratorio de la distribución del incumplimiento, visualización de variables demográficas, preparación del conjunto de entrenamiento, separación de datos en entrenamiento y prueba, escalamiento cuando corresponde, entrenamiento del modelo, búsqueda de hiperparámetros y evaluación mediante métricas como accuracy, precision, recall, F1-score, matriz de confusión, curva ROC y AUC. Finalmente, el flujo permite guardar artefactos del modelo, como el escalador y el modelo entrenado, para su posterior integración con la aplicación interactiva.

En la fase de socialización y reflexión se presentarán los resultados obtenidos mediante visualizaciones, reportes y un tablero interactivo. Esta etapa permitirá analizar el alcance de la solución, interpretar los hallazgos más relevantes, reconocer limitaciones del modelo y proponer mejoras futuras relacionadas con la calidad de los datos, la optimización de algoritmos y el despliegue en entornos productivos.

7.4. Resultados

Como resultado esperado, se obtendrá un sistema predictivo capaz de estimar la probabilidad de impago en clientes financieros a partir de datos previamente procesados y almacenados en una infraestructura híbrida. El proyecto permitirá comparar distintos algoritmos, seleccionar el modelo

con mejor desempeño y presentar los resultados mediante una interfaz interactiva que apoye el análisis del riesgo crediticio.

Además, se espera evidenciar la utilidad de combinar bases de datos relacionales y NoSQL en proyectos de analítica predictiva, así como demostrar la importancia de un pipeline reproducible para garantizar transparencia, trazabilidad y consistencia en el tratamiento de datos. El producto final integrará almacenamiento, procesamiento, modelado y visualización en una solución coherente orientada a resolver una problemática real del entorno financiero.

7.5. Bibliografía

- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media.
- Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.
- Microsoft. (2024). *SQL Server Documentation*. Microsoft Learn.
- MongoDB. (2024). *MongoDB Manual*. MongoDB Documentation.
- Streamlit. (2024). *Streamlit Documentation*. Streamlit Docs.
- Yeh, I.-C. (2009). *Default of Credit Card Clients* [Dataset]. UCI Machine Learning Repository. DOI: 10.24432/C55S3H.

8. Anexos (Evidencias)

En esta sección se presentan las evidencias correspondientes al desarrollo del proyecto, tales como capturas de pantalla de la arquitectura de bases de datos, estructura del conjunto de datos, modelo entidad-relación, visualizaciones y tablero interactivo desarrollado en Streamlit.




Figura 1: Administración de la base de datos del proyecto.




Figura 2: Arquitectura y organización del conjunto de datos.




Figura 3: Diagrama de entidad-relación de la solución.




Figura 4: Modelo E-R empleado para la persistencia de datos.




Figura 5: Visualizaciones generadas para el análisis exploratorio y presentación de resultados.




Figura 6: Tablero interactivo desarrollado en Streamlit.