

Facultad de Ingeniería

Carrera de Ciencia de Datos e IA

Informe de Actividad de Investigación Formativa

Tema

**Desarrollo de un Sistema Predictivo para Evaluar la Probabilidad
de Impago en Clientes Financieros**

Periodo Académico

Abril 2026 – Agosto 2026

Índice

1. Autores	2
2. Personal Académico	2
3. Resultados de Aprendizaje de la Asignatura	2
4. Tema de la Actividad de la Investigación Formativa	3
5. Objetivos de la(s) Actividad(es)	3
6. Fecha de la Ejecución	3
7. Desarrollo del Informe	3
7.1. Introducción	3
7.2. Descripción de la Metodología	4
7.3. Descripción de la(s) Acción(es) Realizadas	5
7.4. Resultados	9
7.5. Bibliografía	22
8. Anexos (Evidencias)	22

1. Autores

- López Cabrera Lenin Francisco
- Jose Mario Camacho Monar
- Brayan Gualberto Cárdenas Medina
- Dennys Alexander Becerra Gavidia
- Dennis Iván Sánchez Palomo

2. Personal Académico

- Director de Carrera: Milton Paúl López Ramos
- Profesor de Asignatura: Raquel Johanna Moyano Arias - Lida Mercedes Barba Maggi

3. Resultados de Aprendizaje de la Asignatura

El desarrollo de esta actividad de investigación formativa permite aplicar conocimientos relacionados con la gestión de datos, el diseño de arquitecturas de persistencia híbrida, la preparación de información para analítica predictiva, la construcción de modelos de Machine Learning y el despliegue de soluciones interactivas orientadas a la toma de decisiones. Además, fortalece competencias de análisis, interpretación de resultados, comunicación técnica y resolución de problemas reales mediante herramientas tecnológicas actuales.

- Utiliza métodos en conjunto (bagging, random forests, extra-trees, boosting, stacking) con buenas prácticas de validación para un adecuado rendimiento y robustez.
- Aplica técnicas de ajuste de hiperparámetros (grid, random, optimización bayesiana) mediante pipelines reproducibles para la optimización de algoritmos y la selección del mejor modelo.
- Aplica técnicas de reducción de dimensionalidad en análisis exploratorio para la visualización de estructuras y la preparación de datos.
- Evalúa algoritmos de clustering (k-means, jerárquico/aglomerativo, DBSCAN, GMM) con métricas internas/externas y diagnósticos para la segmentación de datos de forma consistente.
- Evalúa modelos de bases distribuidas considerando fragmentación, replicación y transparencia.
- Gestiona roles, privilegios y auditorías para garantizar la seguridad y el mantenimiento de bases de datos.
- Compara modelos relacionales y no relacionales para una adecuada implementación.
- Implementa soluciones con bases de datos NoSQL en escenarios prácticos de la administración de datos.

4. Tema de la Actividad de la Investigación Formativa

Desarrollo de un Sistema Predictivo para Evaluar la Probabilidad de Impago en Clientes Financieros.

5. Objetivos de la(s) Actividad(es)

Objetivo general: Diseñar e implementar una solución analítica e infraestructural integral que combine una arquitectura de persistencia híbrida, basada en SQL Server y MongoDB, con el entrenamiento, evaluación y despliegue de modelos de Machine Learning supervisados y no supervisados para evaluar la probabilidad de impago en clientes financieros.

Objetivos específicos:

- Desarrollar un pipeline reproducible de preparación, limpieza y transformación de datos utilizando Python en entornos Jupyter Notebook.
- Implementar una infraestructura de persistencia híbrida que permita almacenar, consultar y gestionar datos estructurados y semiestructurados.
- Construir, optimizar y comparar modelos de aprendizaje supervisado y no supervisado aplicados al análisis del riesgo de impago.
- Evaluar el desempeño de los modelos mediante métricas estadísticas avanzadas que permitan seleccionar la solución más adecuada.
- Desplegar una aplicación interactiva o tablero de control en Streamlit que facilite la visualización de datos, resultados y predicciones en tiempo real.

6. Fecha de la Ejecución

Periodo académico Abril 2026 – Agosto 2026.

7. Desarrollo del Informe

7.1. Introducción

En el sector financiero actual, la capacidad de anticipar el riesgo de impago se ha convertido en un factor estratégico para la toma de decisiones, la sostenibilidad operativa y la reducción de pérdidas asociadas al crédito. Las instituciones financieras gestionan grandes volúmenes de información provenientes de múltiples fuentes, tales como historiales de pago, características sociodemográficas,

comportamiento transaccional, niveles de endeudamiento y registros internos de clientes. Sin embargo, el valor de estos datos depende no solo de su almacenamiento, sino también de la calidad de su gestión, procesamiento, análisis y aprovechamiento mediante soluciones tecnológicas capaces de transformar la información en conocimiento accionable.

En este contexto, el presente proyecto propone el desarrollo de un sistema predictivo orientado a evaluar la probabilidad de impago en clientes financieros, integrando una infraestructura de persistencia híbrida con técnicas de analítica predictiva y modelos de Machine Learning. La solución contempla el uso combinado de SQL Server y MongoDB, con el propósito de aprovechar las fortalezas de las bases de datos relacionales para garantizar integridad, consistencia y gobernanza de la información estructurada, así como la flexibilidad de las bases de datos NoSQL para almacenar y consultar datos semiestructurados o de alta variabilidad. Esta arquitectura busca responder a las necesidades actuales de escalabilidad, trazabilidad y disponibilidad de datos en entornos financieros modernos.

El proyecto incluye el diseño e implementación de un pipeline reproducible de preparación y transformación de datos utilizando Python en entornos Jupyter Notebook. Dicho proceso comprende actividades esenciales como la limpieza de datos, el tratamiento de valores faltantes, la detección de inconsistencias, la codificación de variables, la normalización o estandarización de atributos y la generación de características relevantes para el análisis. Cada decisión de preprocesamiento será justificada técnicamente, considerando su impacto en la calidad del conjunto de datos y en el desempeño de los modelos predictivos.

Asimismo, se construirán, optimizarán y compararán algoritmos de aprendizaje supervisado y no supervisado. Los modelos supervisados permitirán estimar la probabilidad de impago a partir de datos históricos etiquetados, mientras que las técnicas no supervisadas facilitarán la identificación de patrones, segmentos de clientes o comportamientos atípicos que puedan aportar valor al análisis del riesgo financiero. La selección del modelo óptimo se sustentará en métricas estadísticas avanzadas, tales como precisión, sensibilidad, especificidad, F1-score, matriz de confusión, curva ROC y AUC, además de otros indicadores pertinentes según la naturaleza del problema y el balance de clases presente en los datos.

Finalmente, la solución será complementada con el despliegue de una aplicación interactiva o tablero de control desarrollado en Streamlit, mediante el cual los usuarios podrán explorar los datos, visualizar resultados, consultar métricas de desempeño e interactuar en tiempo real con los modelos generados. De esta manera, el sistema no solo busca ofrecer una predicción técnica sobre el riesgo de impago, sino también proporcionar una herramienta práctica de apoyo a la toma de decisiones, fortaleciendo la gestión del riesgo crediticio y demostrando la integración efectiva entre infraestructura de datos, analítica avanzada y despliegue de modelos de Machine Learning.

7.2. Descripción de la Metodología

La metodología del proyecto se desarrollará bajo un enfoque aplicado, experimental y tecnológico. En primer lugar, se realizará la recopilación y análisis de los datos financieros disponibles, identificando las variables relevantes para la evaluación del riesgo de impago. Posteriormente, se diseñará una arquitectura de persistencia híbrida que integre SQL Server para la gestión de datos estructurados

y MongoDB para el manejo de información semiestructurada o flexible.

Para la ejecución del proyecto se utilizarán herramientas orientadas a cubrir las fases de almacenamiento, procesamiento, modelado, visualización y control del desarrollo. La base de datos relacional será implementada en SQL Server 2022, mientras que MongoDB será empleado como base de datos NoSQL para complementar la persistencia de información flexible. El procesamiento de datos y la construcción de modelos de Machine Learning se realizarán con Python 3.12 en entornos Jupyter Notebook, utilizando principalmente las librerías pandas y scikit-learn. Para la visualización y socialización de resultados se emplearán Streamlit y matplotlib, y para el control de versiones se trabajará con Git y GitHub.

- **Base de datos relacional:** SQL Server 2022.
- **Base de datos NoSQL:** MongoDB.
- **Procesamiento y Machine Learning:** Python 3.12, Jupyter Notebook, pandas y scikit-learn.
- **Visualización:** Streamlit y matplotlib.
- **Control de versiones:** Git y GitHub.

El procesamiento de datos se efectuará mediante un pipeline reproducible que incluya limpieza, transformación, análisis exploratorio, selección de variables y preparación del conjunto de entrenamiento. Luego, se entrenarán modelos de Machine Learning supervisados para la predicción del impago y modelos no supervisados para segmentación o detección de patrones. Finalmente, los resultados serán integrados en una aplicación desarrollada con Streamlit, permitiendo la interacción con los datos y los modelos generados.

7.3. Descripción de la(s) Acción(es) Realizadas

Durante la fase de ejecución y seguimiento se seleccionó como fuente principal el conjunto de datos *Default of Credit Card Clients*, obtenido del repositorio UCI Machine Learning Repository. Este dataset corresponde a un problema de clasificación asociado al incumplimiento de pagos de clientes de tarjetas de crédito en Taiwán, y contiene 30.000 registros con información demográfica, crediticia, historial de pagos, montos facturados, pagos realizados y una variable objetivo que indica si el cliente incumplió el pago del mes siguiente. De acuerdo con la documentación del repositorio, el conjunto contiene 23 características predictoras y está orientado a evaluar la probabilidad de incumplimiento crediticio.

A partir del diccionario de variables revisado en la documentación del proyecto, se organizó la información del dataset en grupos funcionales para facilitar su interpretación y posterior uso en el proceso predictivo.

Para la predicción se trabajará con variables que combinan información demográfica, capacidad crediticia, historial de pagos y comportamiento financiero reciente. Estas variables permiten representar tanto el perfil del cliente como su conducta de pago antes de estimar la probabilidad de impago.

Cuadro 1: Diccionario general de variables del dataset.

Variable o grupo		Descripción
<i>ID</i>		Identificador único de cada cliente dentro del conjunto de datos.
<i>LIMIT_BAL</i>		Monto de crédito otorgado al cliente, incluyendo crédito individual y familiar.
<i>SEX</i>		Género del cliente: 1 representa masculino y 2 representa femenino.
<i>EDUCATION</i>		Nivel educativo: 1 posgrado, 2 universidad, 3 bachillerato y 4 otros.
<i>MARRIAGE</i>		Estado civil: 1 casado, 2 soltero y 3 otros.
<i>AGE</i>		Edad del cliente expresada en años.
<i>PAY_0</i> a <i>PAY_6</i>		Historial de estado de pago mensual entre septiembre y abril de 2005. La escala representa pago puntual, crédito revolvente o retrasos de uno a nueve meses.
<i>BILL_AMT1</i> <i>BILL_AMT6</i>	a	Montos de los estados de cuenta mensuales entre septiembre y abril de 2005.
<i>PAY_AMT1</i> <i>PAY_AMT6</i>	a	Montos pagados por el cliente en los meses correspondientes al historial financiero.
<i>default payment next month</i>		Variable objetivo del modelo: 1 indica incumplimiento de pago y 0 indica no incumplimiento.

Cuadro 2: Variables consideradas para el modelo predictivo.

Grupo	Variables	Uso en la predicción
Perfil del cliente	<i>SEX</i> , <i>EDUCATION</i> , <i>MARRIAGE</i> , <i>AGE</i>	Caracterizan al cliente mediante género, nivel educativo, estado civil y edad. Ayudan a identificar patrones demográficos relacionados con el riesgo crediticio.
Capacidad crediticia	<i>LIMIT_BAL</i>	Representa el límite de crédito otorgado y permite aproximar el nivel de exposición financiera del cliente.
Historial de pago	<i>PAY_0</i> , <i>PAY_2</i> , <i>PAY_3</i> , <i>PAY_4</i> , <i>PAY_5</i> , <i>PAY_6</i>	Refleja retrasos o cumplimiento mensual, siendo uno de los grupos más relevantes para detectar riesgo de impago.
Montos facturados	<i>BILL_AMT1</i> <i>BILL_AMT6</i> a	Permiten analizar el nivel de deuda mensual acumulada por el cliente.
Pagos realizados	<i>PAY_AMT1</i> <i>PAY_AMT6</i> a	Indican los pagos efectuados previamente y ayudan a comparar deuda facturada frente a capacidad o voluntad de pago.
Variable objetivo	<i>default payment next month</i>	Clase a predecir: incumplimiento o no incumplimiento del pago del mes siguiente.

Para migrar la información hacia SQL Server se utilizó el script `ScriptsSQL/SQLQuery1.sql`. En primer lugar, el script crea la base de datos `CC_Client` y define tablas de dimensión para normalizar los catálogos de sexo, educación, estado civil, meses de referencia y estatus de pago. Posteriormente, crea la tabla central `dim_cliente`, donde se almacena el perfil del cliente, y las tablas de hechos `historial_pagos` y `riesgo_crediticio`, utilizadas para registrar el comportamiento mensual y la variable objetivo del modelo.

Luego, el proceso de migración carga el archivo del dataset en una tabla temporal o de paso denominada `staging_credit_cards`. Esta tabla conserva la estructura original del archivo, incluyendo variables demográficas, límite de crédito, historial de pago, montos facturados, pagos realizados y el indicador de incumplimiento. A partir de esta tabla, el script inserta los datos normalizados en `dim_cliente` y `riesgo_crediticio`. Finalmente, mediante una operación `CROSS APPLY`, transforma las columnas mensuales del historial financiero en registros por cliente y mes dentro de `historial_pagos`, lo que facilita consultas analíticas, auditoría del comportamiento crediticio y posterior preparación de datos para modelos predictivos.

Adicionalmente, se utilizó el script `ScriptsSQL/SQLQuery2.sql` para complementar la infraestructura de consulta, gobierno y seguridad de la base de datos. Este script crea vistas estructuradas, como `vw_ml_dataset`, que reconstruye un dataset plano listo para procesos de Machine Learning a partir de las tablas normalizadas, y `vw_cliente_detallado`, que integra la información del cliente con descripciones legibles de sexo, educación y estado civil para facilitar el análisis exploratorio. También incorpora índices no agrupados sobre `historial_pagos` y `riesgo_crediticio`, con el objetivo de mejorar el rendimiento de consultas analíticas y filtrados por la variable objetivo.

De forma general, `SQLQuery2.sql` fortalece la administración de la base de datos mediante una tabla de auditoría y un disparador sobre `riesgo_crediticio`, capaz de registrar operaciones de inserción, actualización y eliminación. Además, define roles y usuarios para separar permisos de lectura y administración, estableciendo un rol de analista con acceso de consulta y un rol administrador con control sobre la base de datos. Finalmente, incluye una estrategia de respaldo y restauración mediante backups completos, diferenciales y de log transaccional, lo que contribuye a la disponibilidad, recuperación y gobernanza de la información del proyecto.

La conexión entre la aplicación, las bases de datos y el proceso analítico se implementó desde el archivo `Scrip_pynb/db_connections.py`. Este módulo centraliza las funciones de conexión a SQL Server y MongoDB: en SQL Server se conecta a la base `CC_Client` mediante `pyodbc`, mientras que en MongoDB establece comunicación con el servidor local y retorna la base `ML_Experiments`. Además, incluye funciones para cargar el dataset plano desde la vista `vw_ml_dataset` y el dataset detallado desde `vw_cliente_detallado`, utilizando `pandas` para transformar las consultas SQL en estructuras de datos listas para análisis, visualización y modelado.

Para la etapa de modelado se implementaron tres enfoques complementarios de Machine Learning: K-Means, Random Forest y una red neuronal artificial. K-Means se utilizó como técnica no supervisada para segmentar a los clientes según la similitud de sus características financieras y de pago; Random Forest y la red neuronal se emplearon como técnicas supervisadas para clasificar a los clientes según su probabilidad de impago.

Modelo K-Means. El flujo se desarrolló en el notebook `K-Means/K-Means.ipynb`. Los datos se cargaron desde la vista `vw_ml_dataset` de SQL Server y se excluyeron el identificador del cliente

y la variable objetivo antes de aplicar `StandardScaler`. Para seleccionar el número de grupos se evaluaron valores de k entre 2 y 10 mediante la inercia y el coeficiente de silueta. A partir de este análisis se entrenó el modelo final con tres clústeres, `random_state = 42` y diez inicializaciones. Después se construyeron perfiles por clúster considerando límite de crédito, edad, estado de pago, facturación, pagos realizados y tasa de impago. También se utilizó PCA para representar visualmente los segmentos en dos dimensiones. Finalmente, se guardaron el modelo, el escalador y los centros de los clústeres en los archivos `kmeans_model.pkl`, `scaler.pkl` y `cluster_centers.pkl`; además, se preparó el registro de hiperparámetros y métricas del experimento en MongoDB.

Modelo Random Forest. Este modelo se desarrolló en la carpeta `Random_Forest` mediante los archivos `Processing_RF.py` y `RF_optimizado.py`, complementados por el flujo de entrenamiento base. La preparación incluyó conversión de variables a formato numérico, eliminación de registros nulos, separación de las variables predictoras y la variable objetivo, división estratificada con 80 % de datos para entrenamiento y 20 % para prueba, y normalización mediante `StandardScaler`. El modelo base utilizó 100 árboles y balanceo automático de clases. Posteriormente, la versión optimizada aplicó `GridSearchCV` con validación cruzada de tres pliegues para ajustar el número de árboles, la profundidad y el tamaño mínimo de división y de hoja, priorizando el *recall*. Además, se estableció un umbral de decisión de 0.35 para aumentar la detección de clientes morosos. Los modelos, el escalador y los nombres de las variables se almacenaron como artefactos reutilizables para el despliegue.

Red neuronal artificial. El desarrollo se encuentra en el notebook `red_neuronal/Red_Neuronal.ipynb`, ejecutado en Google Colab. El proceso incluyó la revisión y limpieza de las categorías de educación y estado civil, la eliminación de la columna ID, la separación de 23 variables predictoras y la variable objetivo, y una división estratificada de 24.000 registros para entrenamiento y 6.000 para prueba. Las variables fueron estandarizadas y el escalador se guardó para asegurar el mismo tratamiento durante la inferencia. La arquitectura se implementó con `MLPClassifier`, utilizando dos capas ocultas de 32 y 16 neuronas, activación ReLU, optimizador Adam, tasa de aprendizaje adaptativa, regularización `alpha = 0.0001`, tasa inicial de aprendizaje de 0.001 y un máximo de 50 iteraciones. El modelo se evaluó mediante exactitud, reporte de clasificación, matriz de confusión, curva de pérdida y curva ROC-AUC. Finalmente, se guardaron el modelo `mlp_model.pkl` y el escalador `scaler.pkl` para su integración posterior con la aplicación.

Adicionalmente, se desarrolló un dashboard en Streamlit para la presentación de los modelos creados y de la información gestionada desde la base de datos. Para ello se añadió código en la carpeta `pages`, así como en los archivos `app.py` y `db_connections.py`, los cuales forman parte de la estructura principal de la aplicación interactiva. El archivo `app.py` funciona como punto de entrada del tablero, la carpeta `pages` organiza las vistas o secciones de navegación, y `db_connections.py` permite centralizar la conexión y consulta de información desde las bases de datos utilizadas en el proyecto. Este dashboard facilita la visualización de los segmentos obtenidos con K-Means, la presentación de las predicciones generadas por Random Forest y la red neuronal, y la consulta de datos relevantes para apoyar el análisis del riesgo de impago.

En la fase de socialización y reflexión se presentarán los resultados obtenidos mediante visualizaciones, reportes y un tablero interactivo. Esta etapa permitirá analizar el alcance de la solución, interpretar los hallazgos más relevantes, reconocer limitaciones del modelo y proponer mejoras futuras relacionadas con la calidad de los datos, la optimización de algoritmos y el despliegue en entornos productivos.

7.4. Resultados

Los resultados obtenidos evidencian la integración de la infraestructura de persistencia con los procesos de analítica y modelado. En SQL Server se estructuraron objetos para consulta, rendimiento, auditoría, seguridad y recuperación; mientras que en la etapa de Machine Learning se implementó K-Means para segmentación y se evaluaron Random Forest y una red neuronal artificial para la clasificación del riesgo de impago.

Resultados de la infraestructura de base de datos

Como resultado de la implementación de los scripts SQL se obtuvo una base de datos normalizada y preparada para tareas analíticas. Las vistas permiten reconstruir el conjunto de datos requerido por los modelos y consultar información descriptiva; los índices mejoran las consultas recurrentes; el mecanismo de auditoría registra cambios sobre el riesgo crediticio; y los roles separan las responsabilidades de consulta y administración. Asimismo, quedó definida una estrategia de respaldo completo, diferencial y de log transaccional, junto con la secuencia de restauración correspondiente.

Cuadro 3: Resultados de la implementación en SQL Server.

Componente	Objeto implementado	Resultado
Vistas analíticas	<code>vw_ml_dataset</code> y <code>vw_cliente_detallado</code>	La primera reconstruye un dataset plano de 30.000 clientes para los modelos; la segunda presenta datos demográficos con descripciones legibles para análisis exploratorio.
Optimización	<code>idx_historial_cliente_mes</code> e <code>idx_riesgo_target</code>	Se optimizaron las consultas por cliente, mes y variable objetivo mediante índices no agrupados.
Auditoría	<code>auditoria_cambios</code> y <code>trg_Auditoria_Riesgo</code>	Se habilitó el registro de inserciones, actualizaciones y eliminaciones sobre la tabla de riesgo, conservando usuario, fecha y valores anteriores o posteriores.
Seguridad	<code>rol_analista</code> , <code>rol_admin</code> y usuarios asociados	Se separaron los permisos de solo lectura y administración para aplicar control de acceso según responsabilidades.
Respaldos	Completo, diferencial y log transaccional	Se programó en el script una estrategia escalonada de respaldo y restauración para reducir el riesgo de pérdida de información y facilitar la recuperación de la base <code>CC_Client</code> .

Análisis Exploratorio de Datos (EDA)

El análisis exploratorio realizado en `red_neuronal/Red_Neuronal.ipynb` permitió verificar la calidad del conjunto de datos y reconocer los patrones más relevantes antes del entrenamiento. El dataset contiene 30.000 clientes y 25 columnas, incluyendo la variable objetivo. No se identificaron valores faltantes ni registros duplicados, por lo que no fue necesario eliminar observaciones por problemas de integridad. Las variables fueron organizadas en información demográfica, límite de crédito,

historial mensual de pagos, montos facturados, pagos realizados y estado de incumplimiento.

Cuadro 4: Resumen de los resultados del análisis exploratorio.

Indicador	Resultado
Registros analizados	30.000
Variables del dataset	25
Valores faltantes	0
Registros duplicados	0
Cientes sin incumplimiento	23.364 (77.88 %)
Cientes con incumplimiento	6.636 (22.12 %)
Cientes de sexo femenino	18.112
Cientes de sexo masculino	11.888




Figura 1: Distribución de clientes con y sin incumplimiento de pago.

La distribución de la variable objetivo evidencia un desbalance de clases: aproximadamente ocho de cada diez clientes pertenecen a la clase sin incumplimiento, mientras que solo el 22.12 % corresponde a clientes morosos. Este resultado justifica el uso de división estratificada, métricas como *recall*, F1-score y ROC-AUC, y mecanismos de balanceo durante el entrenamiento. Evaluar únicamente la exactitud podría producir una interpretación optimista, ya que un modelo podría favorecer la clase mayoritaria y aun así dejar sin detectar numerosos casos de impago.

El diagrama de cajas muestra que los clientes con incumplimiento presentan, en términos generales, límites de crédito más bajos que los clientes cumplidos. La mediana y el rango intercuartílico de la clase de impago se sitúan por debajo de los correspondientes a la clase sin impago. En ambas clases existen valores atípicos asociados a límites elevados; sin embargo, la mayor concentración de clientes morosos en niveles crediticios inferiores sugiere una relación inversa entre el límite otorgado y el riesgo de incumplimiento.




Figura 2: Distribución del límite de crédito según el estado de incumplimiento.




Figura 3: Variables con mayor correlación absoluta respecto al incumplimiento.

El historial de pago constituye el grupo de variables más relacionado con el incumplimiento. El estado del mes actual alcanza la correlación más alta, cercana a 0.32, seguido por los estados de los meses anteriores, cuyos valores disminuyen progresivamente desde aproximadamente 0.26 hasta 0.19. Esto indica que los retrasos recientes aportan mayor información predictiva que los retrasos más antiguos. El límite de crédito presenta una correlación aproximada de -0.15 , mientras que los pagos realizados muestran asociaciones negativas de menor magnitud; en consecuencia, mayores límites y mayores pagos previos tienden a relacionarse con una menor probabilidad de impago.




Figura 4: Matriz de correlación de las variables más relevantes para el incumplimiento.

La matriz de correlación confirma una asociación positiva entre los estados de pago de meses consecutivos, con valores que alcanzan aproximadamente 0.82. Esta dependencia temporal indica que el comportamiento de atraso suele mantenerse a lo largo de varios periodos. También se observa una relación negativa entre el límite de crédito y los estados de mora, así como asociaciones moderadas entre los pagos efectuados. Aunque ninguna variable explica por sí sola el incumplimiento, la combinación del historial de mora, el límite disponible, los montos facturados y los pagos anteriores proporciona una base informativa adecuada para los modelos predictivos.

Resultados del modelo K-Means

El modelo K-Means procesó 30.000 registros y 23 variables después de excluir el identificador y la variable objetivo. La evaluación de valores de k entre 2 y 10 permitió seleccionar tres clústeres. El clúster 0 presentó la mayor tasa de impago, con 26.61 %, y concentró clientes con menor límite de crédito y mayor retraso promedio en el pago actual. Los clústeres 1 y 2 mostraron tasas de impago inferiores, de 16.47 % y 18.86 %, respectivamente.

Cuadro 5: Perfil de los clústeres obtenidos con K-Means.

Clúster	Límite	Edad	PAY_0	Factura	Pago	Impago
0	106 144.28	34.52	0.42	44 874.50	3 774.20	26.61 %
1	220 320.59	36.42	-0.76	10 143.22	4 858.34	16.47 %
2	283 672.99	37.02	0.25	200 142.81	16 396.58	18.86 %




Figura 5: Tasa de impago observada en los tres segmentos generados por K-Means.

La figura representa los 30.000 clientes en un plano generado mediante Análisis de Componentes Principales (PCA). El primer componente explica el 28.4 % de la variabilidad del conjunto de datos y el segundo componente explica el 17.8 %, por lo que la visualización resume conjuntamente el 46.2 % de la información original. Los colores identifican los segmentos obtenidos por K-Means: el clúster 1 aparece en rojo, el clúster 0 en azul y el clúster 2 en verde. Los círculos corresponden a clientes que no presentaron impago, mientras que las cruces representan clientes que incumplieron el pago del mes siguiente.

Se observa que el clúster 1 forma el grupo más compacto y se concentra principalmente en valores bajos del primer componente. El clúster 0 se distribuye hacia la zona superior y presenta una separación relativamente clara respecto al clúster 1. Por su parte, el clúster 2 ocupa la región más extensa del gráfico y contiene los casos más dispersos y algunos valores atípicos, lo que indica una mayor heterogeneidad financiera dentro de este segmento. La presencia de círculos y cruces en los tres grupos demuestra que el impago no depende de una única separación lineal; sin embargo, la segmentación permite reconocer perfiles diferenciados que, al combinarse con las tasas de impago




Figura 6: Segmentación de clientes mediante K-Means proyectada en dos dimensiones con PCA.

de cada clúster, aportan información útil para establecer estrategias de seguimiento y gestión del riesgo.




Figura 7: Matriz de confusión obtenida al interpretar K-Means como clasificador binario.

La matriz muestra que los 30.000 clientes fueron asignados a la predicción 0: los 23.364 clientes cumplidos aparecen como verdaderos negativos, mientras que los 6.636 clientes con impago aparecen como falsos negativos. No se generaron predicciones de la clase 1, por lo que los verdaderos positivos y falsos positivos son iguales a cero. Aunque esta salida produciría una exactitud aparente de 77.88 %, dicho valor corresponde únicamente a la proporción de la clase mayoritaria y el *recall* para detectar impagos es 0 %.

Este resultado no debe interpretarse como un fallo del proceso de segmentación, sino como evidencia de que K-Means es un algoritmo no supervisado y sus etiquetas de clúster no representan directamente las clases “cumple” e “impago”. Para utilizar sus grupos como predicciones binarias sería necesario establecer posteriormente una correspondencia entre cada clúster y la clase de riesgo a partir de la tasa de impago observada. Por esta razón, en el proyecto K-Means se considera una herramienta de segmentación y caracterización de perfiles, mientras que Random Forest y la red neuronal se emplean para la predicción supervisada del incumplimiento.

El modelo, el escalador y los centros de los clústeres se guardaron correctamente como artefactos reutilizables. El registro automático del experimento en MongoDB quedó pendiente de repetición debido a que el notebook requiere importar `datetime` antes de construir el documento del experimento.

Resultados del modelo Random Forest

Los resultados se actualizaron a partir del notebook `Random_Forest/Resultados.ipynb`. Este flujo carga los conjuntos previamente procesados mediante `Processing_RF.py` y reutiliza el modelo optimizado almacenado en `random_forest_optimizado.pkl`. En lugar de volver a ejecutar la búsqueda de hiperparámetros, el notebook calcula las probabilidades sobre el conjunto de prueba y aplica un umbral de decisión de 0.35 para priorizar la identificación de clientes con impago.

El conjunto de evaluación contiene 6.000 clientes: 4.673 pertenecen a la clase sin impago y 1.327 a la clase con impago. Con el umbral ajustado, el modelo alcanzó un *recall* de 0.7973, un F1-score de 0.4756 y un ROC-AUC de 0.7743. La exactitud global fue de 0.6112 y la precisión para la clase de impago fue de 0.3389. Este comportamiento responde al objetivo de reducir falsos negativos, aunque implica clasificar como riesgosos a más clientes que finalmente cumplen sus pagos.

Cuadro 6: Resultados del Random Forest optimizado según `Resultados.ipynb`.

Indicador	Resultado
Registros de prueba	6.000
Umbral de decisión	0.35
Accuracy	0.6112
Precision de la clase impago	0.3389
Recall de la clase impago	0.7973
F1-score de la clase impago	0.4756
ROC-AUC	0.7743
Verdaderos negativos	2.609
Falsos positivos	2.064
Falsos negativos	269
Verdaderos positivos	1.058

La matriz de confusión evidencia que el modelo detectó correctamente a 1.058 de los 1.327 clientes morosos y dejó escapar únicamente 269 casos de impago. Esta reducción de falsos negativos es relevante en el ámbito financiero, porque permite identificar cerca del 80 % de los clientes riesgosos antes de conceder o renovar crédito. Como contrapartida, se generaron 2.064 falsos positivos: clientes cumplidos clasificados como morosos. Por ello, el modelo optimizado es apropiado para una estrategia preventiva, pero sus alertas deben complementarse con revisión humana o reglas de negocio para evitar rechazos innecesarios.

El reporte de clasificación confirma esta diferencia entre clases. Para los clientes sin impago se obtuvo una precisión de 0.91, un *recall* de 0.56 y un F1-score de 0.69. Para los clientes con impago se alcanzó una precisión de 0.34, un *recall* de 0.80 y un F1-score de 0.48. La exactitud relativamente baja no implica que el modelo carezca de utilidad; refleja que la configuración fue ajustada deliberadamente para favorecer la sensibilidad sobre la clase minoritaria.

La curva ROC permanece por encima de la diagonal aleatoria y alcanza un área de 0.7743. Este resultado indica una capacidad discriminativa aceptable para ordenar a los clientes desde menor hasta mayor riesgo. El valor AUC se calcula con las probabilidades del modelo y, por tanto, no depende directamente del umbral de 0.35. Esto permite ajustar posteriormente el punto de decisión según el costo institucional de los falsos negativos y falsos positivos sin modificar el modelo entrenado.




Figura 8: Matriz de confusión del Random Forest optimizado con umbral de 0.35.




Figura 9: Curva ROC del Random Forest optimizado.




Figura 10: Quince variables con mayor importancia en el Random Forest optimizado.

El gráfico de importancia muestra que las variables X6, X7, X8 y X9, correspondientes a los estados de pago recientes PAY_0, PAY_2, PAY_3 y PAY_4, concentran la mayor capacidad explicativa. La variable X1, correspondiente al límite de crédito, también se encuentra entre los predictores principales. En posiciones posteriores aparecen los montos pagados y facturados, como X18, X19, X20, X12 y X13. En consecuencia, el modelo basa sus decisiones principalmente en el comportamiento reciente de mora y, de manera complementaria, en la capacidad crediticia y los pagos efectuados.

En términos generales, el Random Forest optimizado cumple el objetivo de detectar la mayor cantidad posible de clientes con riesgo de impago. Su principal fortaleza es el elevado *recall*; su principal limitación es la baja precisión provocada por el aumento de falsos positivos. Para un despliegue operativo se recomienda conservar la probabilidad estimada, permitir el ajuste configurable del umbral y utilizar la predicción como señal de alerta dentro de un proceso de evaluación crediticia más amplio.

Resultados de la red neuronal artificial

De acuerdo con los resultados registrados en `red_neuronal/Red_Neuronal.ipynb`, la red neuronal se entrenó con 24.000 registros y se evaluó con 6.000 registros. La arquitectura MLP de dos capas ocultas alcanzó una exactitud global de 0.8135 y un ROC-AUC de 0.7646. Para la clase de impago obtuvo una precisión de 0.64, un *recall* de 0.36 y un F1-score de 0.46. El entrenamiento finalizó en 3.97 segundos y produjo los artefactos `mlp_model.pkl` y `scaler.pkl`. Estos resultados muestran una buena clasificación global, pero una sensibilidad menor ante la clase minoritaria, por lo que el ajuste de pesos, el umbral de decisión o técnicas de balanceo constituyen oportunidades de mejora.

Cuadro 7: Resultados de la red neuronal artificial.

Indicador	Resultado
Registros de entrenamiento	24.000
Registros de prueba	6.000
Accuracy global	0.8135
ROC-AUC	0.7646
Precision de la clase impago	0.64
Recall de la clase impago	0.36
F1-score de la clase impago	0.46
Verdaderos negativos	4.401
Falsos positivos	272
Falsos negativos	847
Verdaderos positivos	480
Tiempo de entrenamiento registrado	3.97 segundos




Figura 11: Curva de pérdida y matriz de confusión obtenidas durante la evaluación de la red neuronal.

La curva de pérdida desciende de forma pronunciada durante las primeras iteraciones y luego se estabiliza gradualmente alrededor de 0.41, lo que evidencia que el modelo converge dentro de las 50 épocas configuradas. La matriz de confusión muestra 4.401 clientes cumplidos clasificados correctamente y 480 clientes con impago detectados correctamente. Sin embargo, se registraron 847 falsos negativos frente a 272 falsos positivos. Esta diferencia confirma que el modelo favorece la clasificación de la clase mayoritaria y explica el *recall* reducido de la clase de impago.




Figura 12: Curva ROC de la red neuronal para la predicción del riesgo de impago.

La curva ROC se mantiene por encima de la diagonal de clasificación aleatoria y alcanza un área bajo la curva de 0.7646. Esto indica que el modelo posee una capacidad discriminativa aceptable para ordenar clientes según su riesgo, aunque todavía existe margen de mejora en la selección del umbral y en el tratamiento del desbalance entre clientes cumplidos y morosos.

Comparación de los modelos

K-Means cumple una función distinta a los clasificadores: no predice directamente el impago, sino que identifica segmentos de clientes con perfiles financieros similares. Su principal aporte fue revelar un segmento con una tasa de impago de 26.61 %, útil para orientar análisis y políticas diferenciadas de riesgo.

Entre los modelos supervisados, Random Forest base obtuvo la mayor exactitud global, con 0.8177, y la mayor precisión para la clase de impago, con 0.6662; sin embargo, su *recall* de 0.3519 indica que dejó sin detectar una proporción importante de clientes morosos. La red neuronal presentó una exactitud muy cercana, de 0.8135, con un comportamiento igualmente conservador frente a la clase minoritaria. Random Forest optimizado alcanzó el mayor *recall*, con 0.8161, el mayor F1-score, con 0.4722, y redujo los falsos negativos a 244. Por ello, la configuración optimizada resulta más




Figura 13: Comparación de métricas entre Random Forest base, Random Forest optimizado y la red neuronal.

adecuada cuando el costo de no detectar un impago es elevado, aunque exige revisar manualmente una mayor cantidad de falsos positivos.

Cuadro 8: Comparación funcional de los modelos implementados.

Modelo	Finalidad	Fortaleza principal	Limitación principal
K-Means	Segmentación no supervisada	Identifica grupos y tasas de riesgo diferenciadas.	No genera una probabilidad individual de impago.
Random Forest base	Clasificación supervisada	Mayor exactitud y precisión entre los clasificadores.	Recall bajo para la clase de impago.
Random Forest optimizado	Clasificación preventiva	Mayor recall y menor cantidad de falsos negativos.	Incremento de falsos positivos y menor exactitud.
Red neuronal	Clasificación no lineal	Exactitud global competitiva y entrenamiento rápido.	Recall bajo para clientes con impago.

En conjunto, los resultados respaldan una estrategia combinada: K-Means permite caracterizar segmentos de riesgo, Random Forest optimizado prioriza la detección preventiva de posibles impagos y la red neuronal aporta una referencia de clasificación no lineal con alta exactitud global. La selección final debe responder al costo de los falsos negativos y falsos positivos dentro de la política crediticia de la institución.

7.5. Bibliografía

- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media.
- Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.
- Microsoft. (2024). *SQL Server Documentation*. Microsoft Learn.
- MongoDB. (2024). *MongoDB Manual*. MongoDB Documentation.
- Streamlit. (2024). *Streamlit Documentation*. Streamlit Docs.
- Yeh, I.-C. (2009). *Default of Credit Card Clients* [Dataset]. UCI Machine Learning Repository. DOI: 10.24432/C55S3H.

8. Anexos (Evidencias)

Repositorio del proyecto. El código fuente, los scripts SQL, los notebooks de Machine Learning y los componentes de la aplicación pueden revisarse directamente en el repositorio institucional del proyecto: GitHub – IF-Base-datos-Machine-learning. Este acceso permite consultar la estructura completa de la solución, descargar el código y verificar los procesos descritos en el presente informe.

En esta sección se presentan las evidencias correspondientes al desarrollo del proyecto, tales como capturas de pantalla de la arquitectura de bases de datos, estructura del conjunto de datos, modelo entidad-relación, visualizaciones y tablero interactivo desarrollado en Streamlit.




Figura 14: Administración de la base de datos del proyecto.




Figura 15: Arquitectura y organización del conjunto de datos.




Figura 16: Diagrama de entidad-relación de la solución.



Figura 17: Visualizaciones generadas para el análisis exploratorio y presentación de resultados.




Figura 18: Tablero interactivo desarrollado en Streamlit.




Figura 19: Entorno de desarrollo del proyecto en Visual Studio Code.